



# Learning **Intents** behind Interactions with **Knowledge Graph** for Recommendation

*WWW 2021*

*Xiang Wang, Tinglin Huang, Dingxian Wang, Yancheng Yuan,  
Zhengguang Liu, Xiangnan He, Tat-Seng Chua*

汇报人：林欣  
2023年9月1日

1

研究背景

2

研究方法

3

实验结果

4

总结&思考

# 研究背景：个性化推荐

## 想象一下：

今天你很无聊，想要看部电影放松一下，但是当你打开视频软件时，面对数不胜数的电影，你很容易感到手足无措，不知道该看什么。



## 个性化推荐系统



可以根据你的历史观影记录分析你的电影偏好，从庞大的电影库中找到几部符合你兴趣的电影供你选择。

# 研究背景：个性化推荐

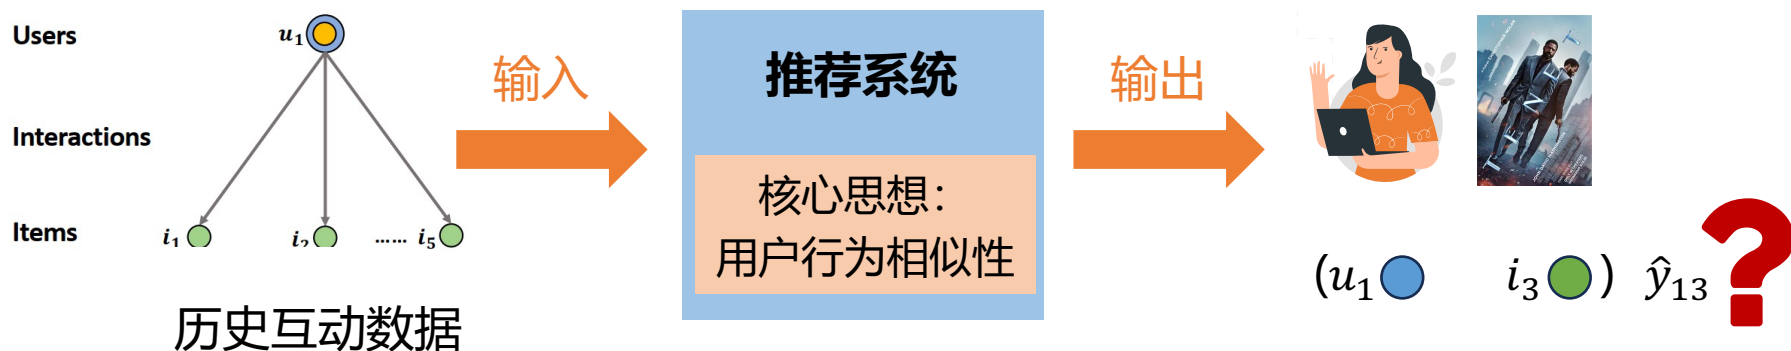
- 在信息过载时代，从大量信息中找到自己感兴趣的信息十分困难
- 个性化推荐系统将用户和信息联系起来，在无明确需求的情况下快速发现自己感兴趣的信息
- 在电子商务、社交网络以及多种内容分享平台上广泛应用



# 研究背景：个性化推荐

## • 推荐问题定义

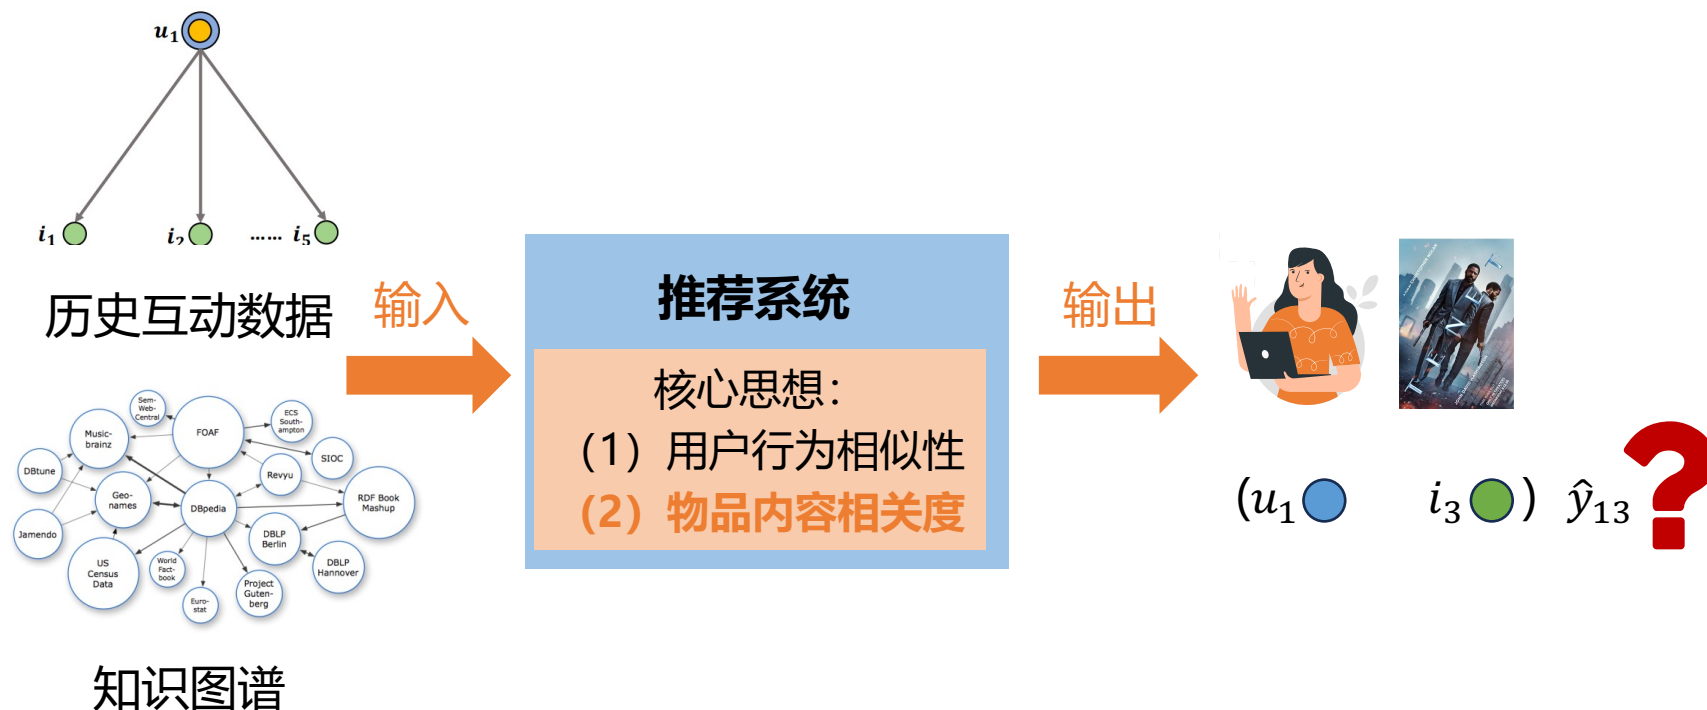
- **输入：**用户与物品交互的历史数据（比如：点击、访问、购买等）
- **输出：**用户与给定物品交互的概率大小



# 研究背景：基于知识图谱的推荐系统

- 额外的输入：知识图谱 (KG)

- 存在丰富的语义信息和实体关系
- 有助于揭示物品之间的联系，并可以用来解释用户的偏好




# 研究背景：基于知识图谱的推荐系统

## • 现有工作大致可以分成四类

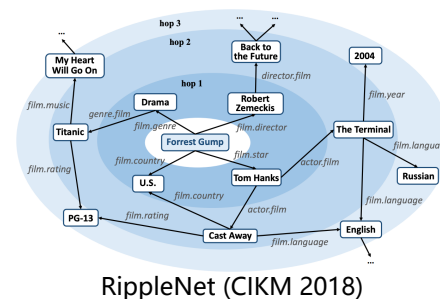
### 基于表征

- 关注一阶连通性，利用KG Embedding技术获取实体表示，并作为先验知识补充到推荐模型
- 忽略了高阶连通性，无法捕获长距离关系依赖



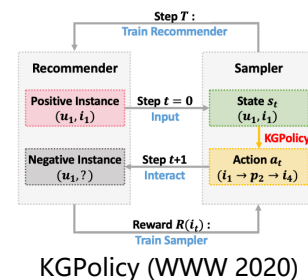
### 基于路径

- 挖掘用户和物品之间的路径来捕获长距离连通
- 推荐准确性与路径质量密切相关，然而现有两种路径挖掘方法都存在局限（暴力搜索耗时耗力、meta-path迁移性差）




### 基于策略

- 设计强化学习智能体来学习寻找路径的策略，基于强化学习的策略网络可看作高效且便宜的暴力搜索
- 回报稀疏、动作空间巨大使得网络很难训练和收敛




### 基于GNN

- 基于信息聚合技术，迭代地聚合邻居信息从而表示多跳节点
- 在建模用户意图和感知关系路径上仍存在局限性



# 基于GNN工作的局限1：用户意图

- 现有工作将用户和物品之间的关系建模成单一关系，而忽略了用户往往在考虑物品时是出于多种意图，容易混淆对用户行为的建模。



- 以电影为例
- 意图 $p_1$ 表示了由 $r_1$ 导演和 $r_2$ 主演两种关系所主导，因此观看了电影 $i_1$ 和 $i_5$
- 意图 $p_2$ 表示了由 $r_3$ 搭档和 $r_2$ 主演两种关系所主导，因此观看了电影 $i_2$ 和 $i_5$
- 同样是观看电影 $i_5$ ，可能有2种不同意图

推荐系统的基本逻辑：相似用户会在物品交互上具有相似的偏好



现有基于GNN的工作：用户行为相似性（容易受到模糊意图的混淆）



对用户意图进行细粒度建模

当前工作想法：基于用户意图的行为相似性




# 基于GNN工作的局限2：关系路径


- 现有工作在GNN聚合信息时，基于邻居节点收集信息，而**没有分辨这是来自哪一条路径**的信息，难以保存**长关系依赖**和**基于路径的序列**。

## 基于节点

- 1跳:  $\{i_1, i_2\}$
- 2跳:  $\{v_1, v_2, v_3\}$
- 3跳:  $\{v_3\}$



Node-based Neighborhood Aggregation



Relational Path Neighborhood Aggregation

## 基于路径

- 1跳:  $u_1 \xleftarrow{p_1} i_1$
- 2跳:  $u_1 \xleftarrow{p_1} i_1 \xleftarrow{r_2} v_2$
- 3跳:  $u_1 \xleftarrow{p_1} i_1 \xleftarrow{r_2} v_2 \xleftarrow{r_3} v_3$
- $u_1$  &  $v_3$  的关系依赖表示为  $(p_1, r_2, r_3)$

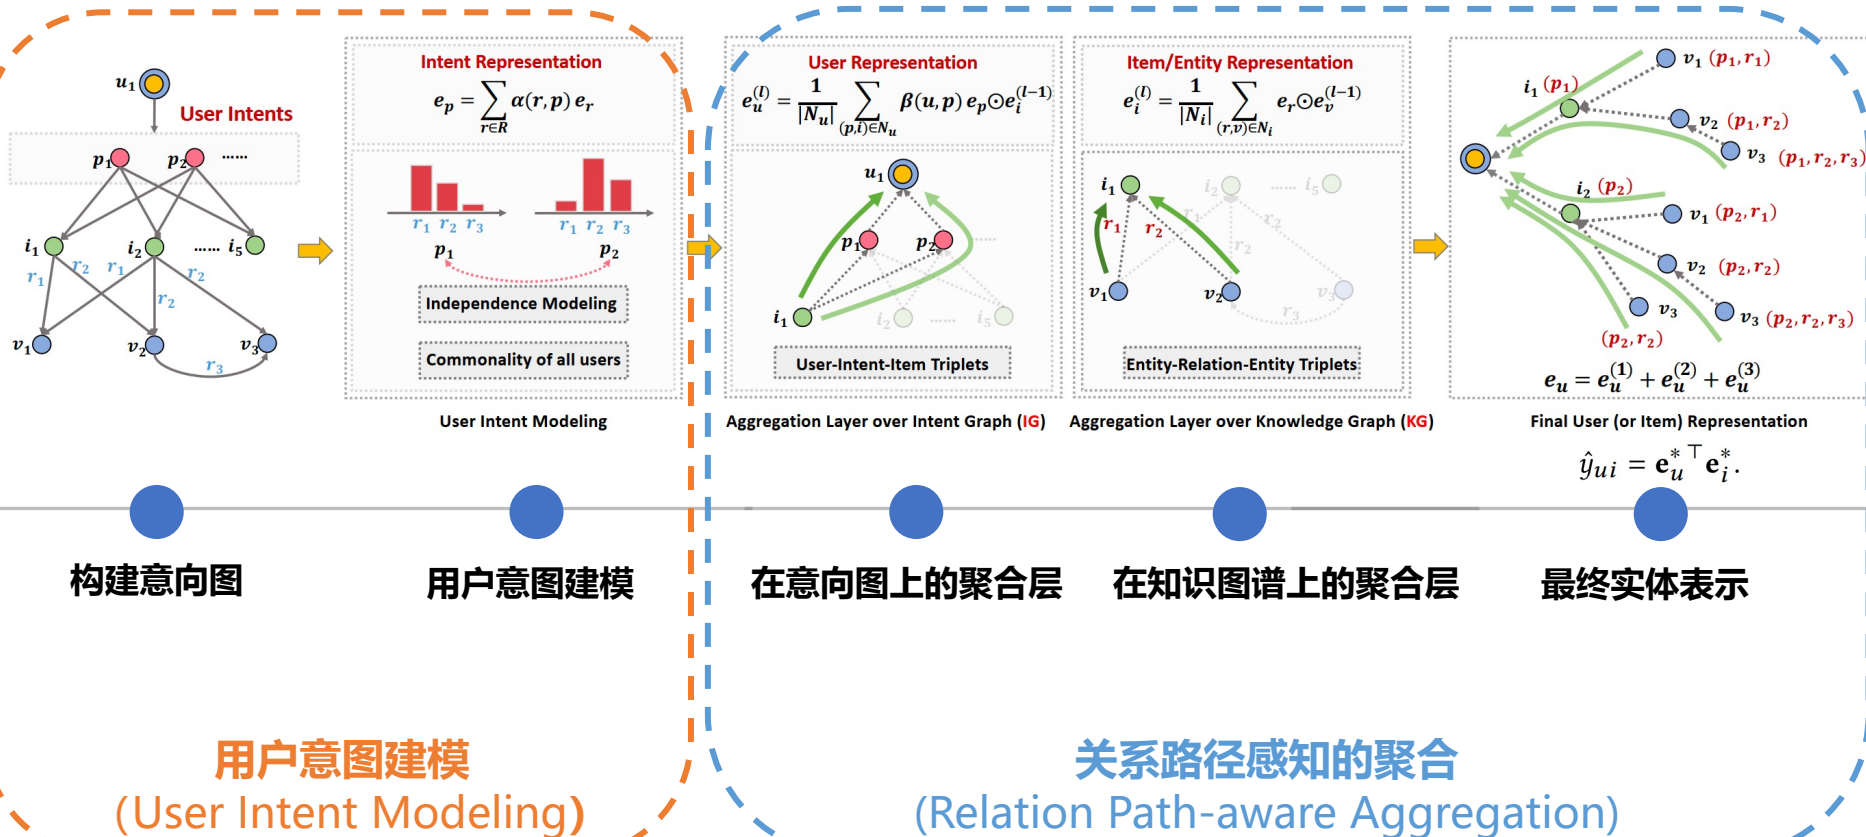
现有基于GNN的工作：基于节点来聚合信息 (难以捕捉关系路径)



基于路径聚合

当前工作想法：将关系路径看作信息通道进行聚合

## Knowledge Graph-based Intent Network(KGIN)



## 研究方法


2

用户意图建模

关系路径感知的聚合

# KGIN: 用户意图建模 (1)

- 第1步: 表征“用户意图”
- KG关系能够显式地表达用户意图, 引入注意力机制给每个意图分配一个KG关系分布, 实现对用户意图的表征  $e_p$



将  $(u, i)$  重新组织成  $(u, p, i)$   
将互动数据重新组织成意向图(IG)

所有用户共享的意图表征

$$\mathbf{e}_p = \sum_{r \in \mathcal{R}} \alpha(r, p) \mathbf{e}_r,$$

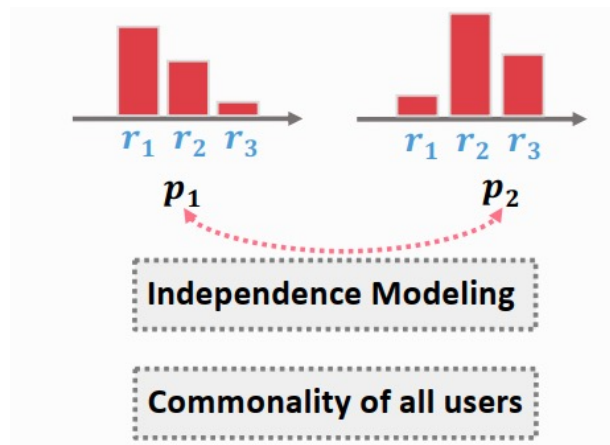
在KG关系编码上的注意力组合

$$\alpha(r, p) = \frac{\exp(w_{rp})}{\sum_{r' \in \mathcal{R}} \exp(w_{r'p})},$$

量化关系  $r$  对意图  $p$  的重要性

# KGIN: 用户意图建模 (2)

- 第2步：用户意图的独立建模
- 思路：不同意图应包含不同信息，相互有所区别
  - > 在意图表征中加入独立性正则化



- 互信息

$$\mathcal{L}_{\text{IND}} = \sum_{p \in \mathcal{P}} -\log \frac{\exp(s(\mathbf{e}_p, \mathbf{e}_p)/\tau)}{\sum_{p' \in \mathcal{P}} \exp(s(\mathbf{e}_p, \mathbf{e}_{p'})/\tau)},$$

最小化任意两个不同意图之间的信息量

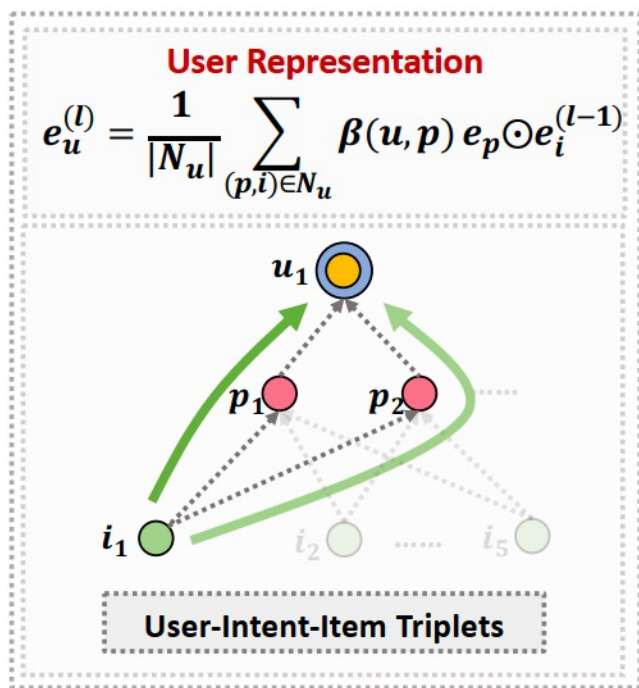
- 距离相关性

$$\mathcal{L}_{\text{IND}} = \sum_{p, p' \in \mathcal{P}, p \neq p'} d\text{Cor}(\mathbf{e}_p, \mathbf{e}_{p'}),$$

最小化任意两个不同意图之间的联系

# KGIN: 关系路径感知聚合 (1)

- 第1步: 意向图 (IG) 上的聚合
- 思路: 具有相似意图的用户在物品交互上具有相似的偏好。
  - > 基于user-intent-item三元组  $(u, p, i)$  实现感知意图的信息聚合



Aggregation Layer over Intent Graph (IG)

将意图  $p$  与历史物品  $i$  对应的表示按元素相乘  $\odot$

$$\mathbf{e}_u^{(1)} = \frac{1}{|\mathcal{N}_u|} \sum_{(p, i) \in \mathcal{N}_u} \boxed{\beta(u, p)} \boxed{\mathbf{e}_p \odot \mathbf{e}_i^{(0)}}$$

$$\boxed{\beta(u, p)} = \frac{\exp(\mathbf{e}_p^\top \mathbf{e}_u^{(0)})}{\sum_{p' \in \mathcal{P}} \exp(\mathbf{e}_{p'}^\top \mathbf{e}_u^{(0)})}$$

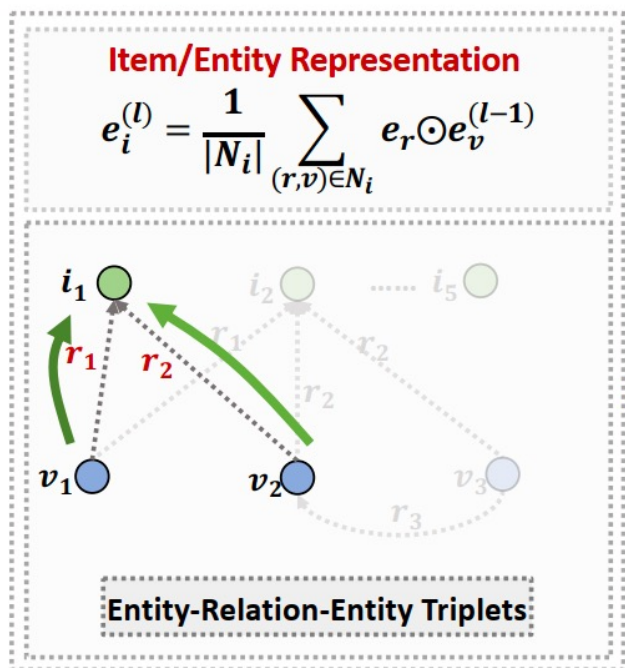
区别不同意图  $p$ , 生成用户特定的意图表示  $\beta(u, p)$



- (1) 不同意图  $p$  在用户决策过程中贡献应是不同的
- (2) 由意图来引导信息聚合, 而不是衰减因子或正则项

# KGIN: 关系路径感知聚合 (2)

- 第2步：知识图谱 (KG) 上的聚合
- 思路：KG实体在不同关系上下文中具有不同的语义信息。
  - > 基于item-relation-entity 三元组  $(i, r, v)$  实现感知关系的信息聚合



Aggregation Layer over Knowledge Graph (KG)

将相关的连接实体都作为一种属性，从而衡量实体之间的内容相似性。 (举例子)

将关系 $r$ 与连接实体 $v$  对应的表示按元素相乘  $\odot$


$$e_i^{(1)} = \frac{1}{|N_i|} \sum_{(r,v) \in N_i} e_r \odot e_v^{(0)}$$

将实体之间的关系作为投影因子，捕捉同一实体不同关系的不同语义联系。



# KGIN: 关系路径感知聚合 (2)

## 第3步：捕获关系路径



Final User (or Item) Representation

- 第1层表示  $\mathbf{e}_i^{(1)} = \frac{1}{|\mathcal{N}_i|} \sum_{(r,v) \in \mathcal{N}_i} \mathbf{e}_r \odot \mathbf{e}_v^{(0)}$ ,
- 第 $l$ 层表示  $\mathbf{e}_i^{(l)} = \sum_{s \in \mathcal{N}_i^l} \left[ \frac{\mathbf{e}_{r_1}}{|\mathcal{N}_{s_1}|} \odot \frac{\mathbf{e}_{r_2}}{|\mathcal{N}_{s_2}|} \odot \dots \odot \frac{\mathbf{e}_{r_l}}{|\mathcal{N}_{s_l}|} \odot \mathbf{e}_{s_l}^{(0)} \right]$ ,

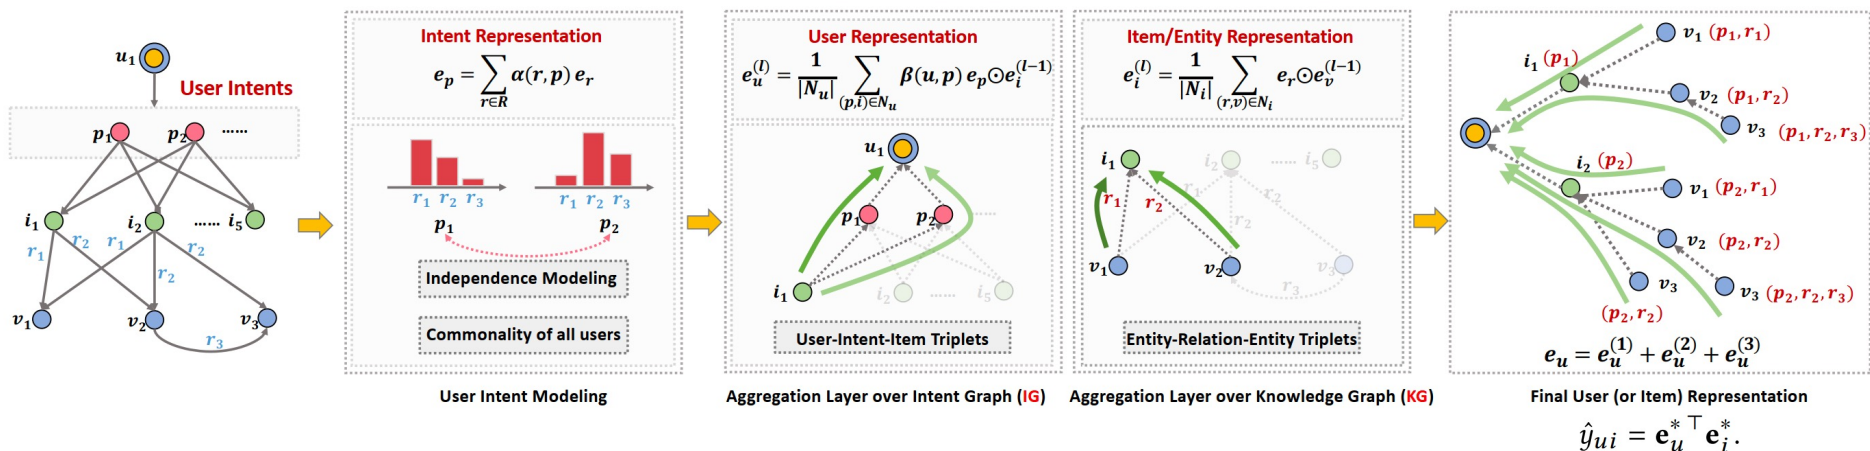
- 反映了关系中的交互
- 保存了路径中的语义内容

$$S = i \xrightarrow{r_1} s_1 \xrightarrow{r_2} \dots s_{l-1} \xrightarrow{r_l} s_l$$

- 最终表示  $\mathbf{e}_i^* = \mathbf{e}_i^{(0)} + \dots + \mathbf{e}_i^{(L)}$ .
- 用户-物品交互概率  $\hat{y}_{ui} = \mathbf{e}_u^{*T} \mathbf{e}_i^*$ .



## Knowledge Graph-based Intent Network(KGIN)



BPR损失：保证访问过物品的得分要高于没访问的物品

最小化最终损失函数

$$\mathcal{L}_{\text{BPR}} = \sum_{(u, i, j) \in O} -\ln \sigma(\hat{y}_{ui} - \hat{y}_{uj}),$$

$$O = \{(u, i, j) | \boxed{u, i \in O^+, u, j \in O^-}\}$$

$$\mathcal{L}_{\text{KGIN}} = \mathcal{L}_{\text{BPR}} + \lambda_1 \mathcal{L}_{\text{IND}} + \lambda_2 \|\Theta\|_2^2,$$

**实验分析**

**3**

**数据设置**

**实验结果**

**实验分析**

- **RQ1:** 与目前知识驱动的sota推荐模型相比, KGIN表现如何?
- **RQ2:** 模型的设计对于推进KGIN关系建模上有何影响?  
(e.g., 用户意图的个数、独立性, 关系路径的深度)
- **RQ3:** KGIN能否提供关于用户意图的一些见解? 并给出直观的可解释结果?

- **数据集:** Amazon-Book, Last-FM, Alibaba-iFashion (开源)
- **评估指标:** recall@k, ndcg@k (k=20)

**Table 1: Statistics of the datasets.**

		Amazon-Book	Last-FM	Alibaba-iFashion
User-Item Interaction	#Users	70,679	23,566	114,737
	#Items	24,915	48,123	30,040
	#Interactions	847,733	3,034,796	1,781,093
Knowledge Graph	#Entities	88,572	58,266	59,156
	#Relations	39	9	51
	#Triplets	2,557,746	464,567	279,155

# 实验结果 (RQ1)

- KGIN考虑了隐含的**用户意图**，更好地建模了user-item互动关系
- KGIN通过感知关系路径，保存了**路径中的完整语义**，从KG中获取了更多信息
- KGIN在IG和KG上应用不同聚合方式，更好地将联合信号和物品知识到嵌入到用户和物品表征中

Table 2: Overall performance comparison.

基线模型		Amazon-Book		Last-FM		Alibaba-iFashion	
		recall	ndcg	recall	ndcg	recall	ndcg
经典CF模型 基于表征的模型	MF	0.1300	0.0678	0.0724	0.0617	0.1095	0.0670
	CKE	0.1342	0.0698	0.0732	0.0630	<u>0.1103</u>	<u>0.0676</u>
基于GNN的模型	KGAT	<u>0.1487</u>	<u>0.0799</u>	0.0873	<u>0.0744</u>	0.1030	0.0627
	KGNN-LS	0.1362	0.0560	<u>0.0880</u>	0.0642	0.1039	0.0557
	CKAN	0.1442	0.0698	0.0812	0.0660	0.0970	0.0509
	R-GCN	0.1220	0.0646	0.0743	0.0631	0.0860	0.0515
	KGIN-3	<b>0.1687*</b>	<b>0.0915*</b>	<b>0.0978*</b>	<b>0.0848*</b>	<b>0.1147*</b>	<b>0.0716*</b>
相对提升		%Imp.					
		13.44%	14.51%	11.13%	13.97%	3.98%	5.91%

# 实验分析 (RQ2)

- 引入意图建模和关系语义建模能够提升模型性能
- 多数情况下，增加关系路径的聚合层数可以提升预测结果
- 多数情况下，增加意图个数（即探索多样的意图）有助于提高性能。  
由于独立性建模鼓励意图之间的不相关性，当意图的个数太多，可能会导致粒度过细，丢失有效信息。

Table 3: Impact of presence of user intents and KG relations.

	Amazon-Book		Last-FM		Alibaba-iFashion	
	recall	ndcg	recall	ndcg	recall	ndcg
w/o I&R	0.1518	0.0816	0.0802	0.0669	0.0862	0.0530
w/o I	0.1627	0.0870	0.0942	0.0819	0.1103	0.0678

Table 4: Impact of the number of layers  $L$ .

	Amazon-Book		Last-FM		Alibaba-iFashion	
	recall	ndcg	recall	ndcg	recall	ndcg
KGIN-1	0.1455	0.0766	0.0831	0.0707	0.1045	0.0638
KGIN-2	0.1652	0.0892	0.0920	0.0791	0.1162	0.0723
KGIN-3	0.1687	0.0915	0.0978	0.0848	0.1147	0.0716

Table 5: Impact of independence modeling.

	Amazon-Book		Last-FM		Alibaba-iFashion	
	w/ Ind	w/o Ind	w/ Ind	w/o Ind	w/ Ind	w/o Ind
distance correlation	0.0389	0.3490	0.0365	0.4944	0.0112	0.3121





Figure 4: Impact of intent number ( $|\mathcal{P}|$ ). Best viewed in color.

# 实验分析 (RQ3)

- KGIN的可解释性:** 可以提供实例级别的解释


## Amazon-Book

	Top 2 KG Relations in Each Intent	Score
<b>p1</b>	$r_{65}$ (theater.play.genre)	0.2368
	$r_{34}$ (theater.plays in this genre)	0.1623
<b>p2</b>	$r_{76}$ (book.date_written)	0.3567
	$r_{63}$ (book.short_story.genre)	0.2283
<b>p3</b>	$r_{71}$ (date_of_first_performance)	0.5934
	$r_{30}$ (fictional_universe.)	0.1418
<b>p4</b>	$r_{65}$ (theater.play.genre)	0.1230
	$r_{27}$ (book.illustrator)	0.1040



## Last-FM

	Top 2 KG Relations in Each Intent	Score
<b>p1</b>	$r_{17}$ (featured_artist)	0.4945
	$r_{15}$ (versions)	0.3569
<b>p2</b>	$r_{15}$ (versions)	0.4694
	$r_6$ (song)	0.0881
<b>p3</b>	$r_{15}$ (versions)	0.4472
	$r_{17}$ (featured_artist)	0.1497
<b>p4</b>	$r_{12}$ (engineer)	0.1888
	$r_{15}$ (versions)	0.1564



**总结 & 思考 4**

**论文优点**

**个人思考**



## ■ 优点 (Take-home Messages)

- 从意图粒度来揭露用户-物品的关系，同时基于KG关系来建模意图，推动结果可解释
- 从多跳路径中整合关系信息，提出了关系路径感知的信息聚合方式

## ■ 个人思考

- 关注为什么要这么设计？怎么想到要这么设计的？
- 用户意图建模：够好了吗？
- 作者的未来工作：整合因果概念来辨别意图是否与用户行为具有因果关系